KECERDASAN BUATAN



Nama	:	Bryan Torisi Siagian
NIM	:	42324029
Prodi	:	D3 Teknologi Informasi

FAKULTAS VOKASI

INSTITUT TEKNOLOGI DEL

2026/2027

1. Memuat Dataset Klasifikasi Teks

Cell ini berfungsi untuk membaca berkas dataset Text_classification.csv ke dalam bentuk DataFrame menggunakan pustaka Pandas, lalu menampilkan 5 baris pertama data untuk memeriksa struktur kolom seperti kategori pesan dan isi pesannya.

```
import pandas as pd
df = pd.read_csv('Text_classification.csv')
print(df.head())
```

```
  Category                                            Message
0      ham  Go until jurong point, crazy.. Available only ...
1      ham                      Ok lar... Joking wif u oni...
2     spam  Free entry in 2 a wkly comp to win FA Cup fina...
3      ham  U dun say so early hor... U c already then say...
4      ham  Nah I don't think he goes to usf, he lives aro...
```

2. Preprocessing Teks dan Pemuatan Modul NLTK

Cell ini berfungsi untuk mengunduh sumber daya pustaka NLTK yang diperlukan, mengimpor modul pendukung pemrosesan teks, serta mendefinisikan fungsi clean_text untuk mengubah teks menjadi huruf kecil, menghapus angka dan tanda baca, melakukan tokenisasi, menyaring stopwords, dan melakukan lemmatisasi sebelum diterapkan ke seluruh data teks.

```python
# Download resource NLTK yang diperlukan
import nltk    Import "nltk" could not be resolved
nltk.download('punkt_tab')
nltk.download('punkt')
nltk.download('stopwords')
nltk.download('wordnet')

# Import Library untuk preprocessing
import re
import string
from nltk.corpus import stopwords    Import "nltk.corpus" could not be resolved
from nltk.tokenize import word_tokenize    Import "nltk.tokenize" could not be resolved
from nltk.stem import WordNetLemmatizer    Import "nltk.stem" could not be resolved

# Inisialisasi Lemmatizer
lemmatizer = WordNetLemmatizer()

# Fungsi preprocessing teks
def clean_text(text):
    text = text.lower() # Ubah menjadi Lowercase
    text = re.sub(r'\d+', '', text) # Hapus angka
    text = text.translate(str.maketrans('', '', string.punctuation)) # Hapus tanda baca
    words = word_tokenize(text) # Tokenisasi
    words = [word for word in words if word not in stopwords.words('english')] # Hapus stopwords
    words = [lemmatizer.lemmatize(word) for word in words] # Lemmatization
    return ' '.join(words)

# Terapkan preprocessing ke teks
df['clean_text'] = df['Message'].apply(clean_text)

# Cek hasil preprocessing
print("\nHasil Preprocessing:\n", df[['Message', 'clean_text']].head())
```

```
[nltk_data] Downloading package punkt_tab to
[nltk_data]     C:\Users\WIN11\AppData\Roaming\nltk_data...
[nltk_data]   Unzipping tokenizers\punkt_tab.zip.
[nltk_data] Downloading package punkt to
[nltk_data]     C:\Users\WIN11\AppData\Roaming\nltk_data...
[nltk_data]   Unzipping tokenizers\punkt.zip.
[nltk_data] Downloading package stopwords to
[nltk_data]     C:\Users\WIN11\AppData\Roaming\nltk_data...
[nltk_data]   Unzipping corpora\stopwords.zip.
[nltk_data] Downloading package wordnet to
[nltk_data]     C:\Users\WIN11\AppData\Roaming\nltk_data...

Hasil Preprocessing:
                                                 Message  \
0  Go until jurong point, crazy.. Available only ...
1                      Ok lar... Joking wif u oni...
2  Free entry in 2 a wkly comp to win FA Cup fina...
3  U dun say so early hor... U c already then say...
4  Nah I don't think he goes to usf, he lives aro...

                                          clean_text
0  go jurong point crazy available bugis n great ...
1                            ok lar joking wif u oni
2  free entry wkly comp win fa cup final tkts st ...
3                u dun say early hor u c already say
4           nah dont think go usf life around though
```

3. Transformasi Label Kelas

Cell ini berfungsi untuk mengubah label kategori teks dari 'ham' dan 'spam' menjadi nilai numerik biner 0 dan 1, serta menghitung jumlah total data pada masing-masing kelas untuk melihat sebaran distribusi datanya.

```
    # Ubah Label dari 'ham'/'spam' menjadi 0/1
    df['Category'] = df['Category'].map({'ham': 0, 'spam': 1})

    # Cek jumlah masing-masing kelas
    print(df['Category'].value_counts())


Category
0    4825
1     747
Name: count, dtype: int64
```

4. Pembagian Data Latih dan Data Uji

Cell ini berfungsi untuk memisahkan kolom fitur teks bersih dan label numerik, lalu membagi dataset menjadi data latih (training) sebesar 80% dan data uji (testing) sebesar 20% menggunakan fungsi train_test_split dengan parameter stratify=y.

```
    from sklearn.model_selection import train_test_split    Import "sklearn.model_selection" could not be resolved from source

    # Pisahkan fitur dan Label
    X = df['clean_text']
    y = df['Category']

    # Split data (80% training, 20% testing)
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)
```

5. Ekstraksi Fitur Menggunakan TF-IDF

Cell ini berfungsi untuk mengonversi data teks menjadi representasi vektor numerik menggunakan TfidfVectorizer dengan rentang ngram (unigram dan bigram) serta membatasi jumlah fitur maksimal sebanyak 5000 kata penting.

```
    from sklearn.feature_extraction.text import TfidfVectorizer    Import "sklearn.feature_extraction.text" could not be resolved from source

    # Konversi teks menjadi fitur numerik menggunakan TF-IDF
    vectorizer = TfidfVectorizer(ngram_range=(1,2), max_features=5000) # Menggunakan bigram
    X_train_tfidf = vectorizer.fit_transform(X_train)
    X_test_tfidf = vectorizer.transform(X_test)

    print("\nTF-IDF Shape (Train):", X_train_tfidf.shape)


TF-IDF Shape (Train): (4457, 5000)
```

6. Pelatihan Model Naïve Bayes

Cell ini berfungsi untuk menginisialisasi model klasifikasi Multinomial Naïve Bayes dengan parameter smoothing, melatih model menggunakan data latih TF-IDF, serta melakukan prediksi label pada data uji.

```
from sklearn.naive_bayes import MultinomialNB    Import "sklearn.naive_bayes" could not be resolved from source

# Inisialisasi model Naïve Bayes
model = MultinomialNB(alpha=0.1)

# Train model
model.fit(X_train_tfidf, y_train)

# Prediksi hasil
y_pred = model.predict(X_test_tfidf)
```

7. Evaluasi Performa Model

Cell ini berfungsi untuk mengukur kinerja model klasifikasi dengan menghitung nilai akurasi total menggunakan accuracy_score serta menampilkan laporan metrik evaluasi lengkap meliputi precision, recall, dan f1-score melalui classification_report.

```
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# Akurasi
accuracy = accuracy_score(y_test, y_pred)
print("\nAccuracy:", accuracy)

# Classification Report
print("\nClassification Report:\n", classification_report(y_test, y_pred))



Accuracy: 0.979372197309417

Classification Report:
              precision    recall  f1-score   support

           0       0.98      1.00      0.99       966
           1       0.98      0.86      0.92       149

    accuracy                           0.98      1115
   macro avg       0.98      0.93      0.95      1115
weighted avg       0.98      0.98      0.98      1115
```

8. Visualisasi Confusion Matrix

Cell ini berfungsi untuk menghitung matriks kebingungan (confusion matrix) dari hasil prediksi, mengekstrak nilai TP, TN, FP, dan FN, serta memvisualisasikannya ke dalam bentuk diagram peta panas (heatmap) berwarna biru.

```python
# Confusion Matrix
import seaborn as sns    Import "seaborn" could not be resolved from source
import matplotlib.pyplot as plt    Import "matplotlib.pyplot" could not be resolved from source
import numpy as np
import pandas as pd
from sklearn.metrics import confusion_matrix    Import "sklearn.metrics" could not be resolved from source

# Hitung confusion matrix
conf_matrix = confusion_matrix(y_test, y_pred)

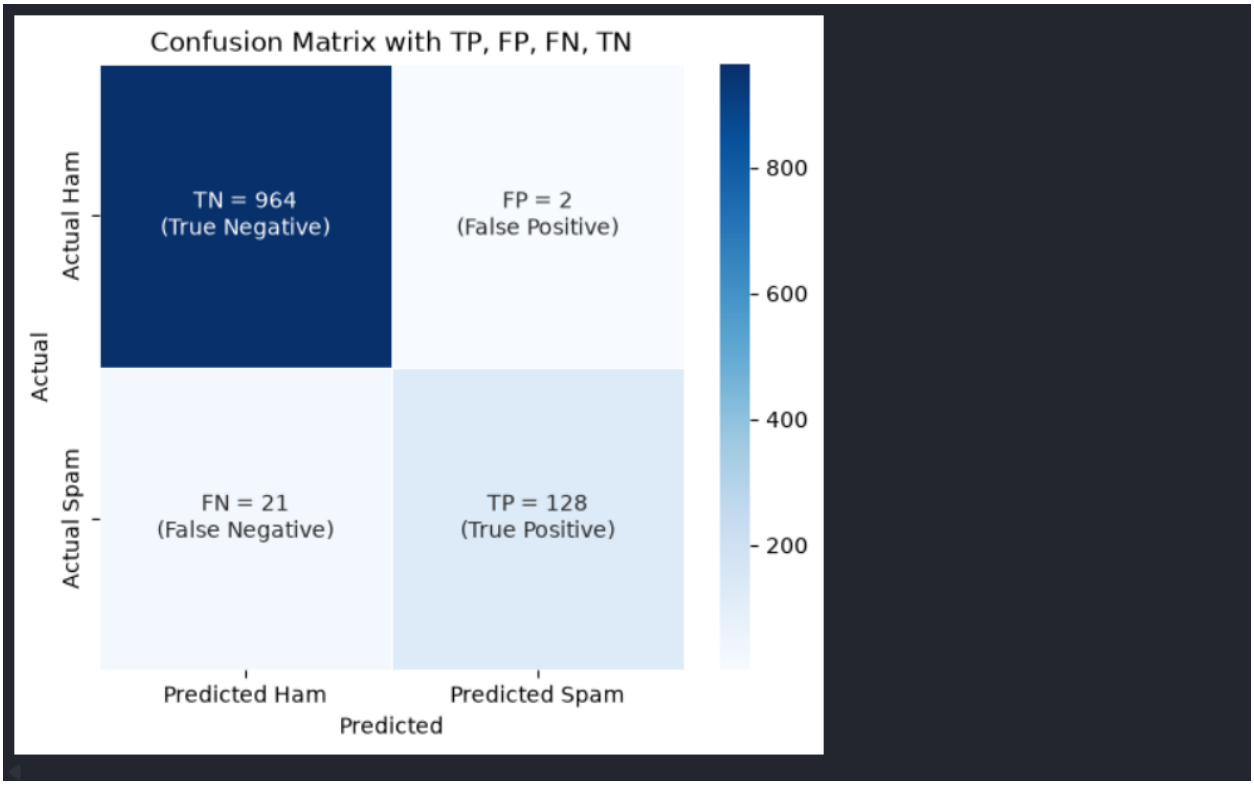
# Definisi elemen dalam confusion matrix
TN, FP, FN, TP = conf_matrix.ravel()

# Buat dataframe confusion matrix
df_conf_matrix = pd.DataFrame(conf_matrix, index=['Actual Ham', 'Actual Spam'], columns=['Predicted Ham', 'Predicted Spam'])

# Label untuk TP, FP, FN, TN
labels = np.array([["TN = {}\n(True Negative)".format(TN), "FP = {}\n(False Positive)".format(FP)],
                   ["FN = {}\n(False Negative)".format(FN), "TP = {}\n(True Positive)".format(TP)]])

# Plot heatmap dengan keterangan
plt.figure(figsize=(6,5))
ax = sns.heatmap(df_conf_matrix, annot=labels, fmt='', cmap='Blues', linewidths=0.5, cbar=True)

# Tambahkan Label
plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title('Confusion Matrix with TP, FP, FN, TN')
plt.show()
```



9. Pengujian Model pada Teks Baru

Cell ini berfungsi untuk menguji model secara langsung menggunakan contoh pesan teks baru di luar dataset, di mana teks tersebut melalui proses pembersihan dan transformasi TF-IDF sebelum diprediksi statusnya sebagai Spam atau Ham.

```python
# Contoh teks baru
new_texts = ["Congratulations! You won a free trip to Bali.",
             "Hey, are you coming to the party tonight?"]

# Preprocess teks baru
new_texts_clean = [clean_text(text) for text in new_texts]

# Transformasi dengan TF-IDF
new_texts_tfidf = vectorizer.transform(new_texts_clean)

# Prediksi
predictions = model.predict(new_texts_tfidf)

# Output hasil prediksi
for text, label in zip(new_texts, predictions):
    print(f"\nMessage: {text} \nPredicted: {'Spam' if label == 1 else 'Ham'}")
```

```
Message: Congratulations! You won a free trip to Bali.
Predicted: Spam

Message: Hey, are you coming to the party tonight?
Predicted: Ham
```