KECERDASAN BUATAN



Nama	:	Bryan Torisi Siagian
NIM	:	42324029
Prodi	:	D3 Teknologi Informasi

FAKULTAS VOKASI

INSTITUT TEKNOLOGI DEL

2026/2027

1.

```
# Import Library
import pandas as pd
import numpy as np
import re
import string
from nltk.tokenize import word_tokenize
from nltk.stem import WordNetLemmatizer
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.cluster import KMeans
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt
```

✓ 10.2s

Berfungsi untuk memuat atau mengimpor seluruh pustaka (*library*) Python yang diperlukan ke dalam program. Pustaka-pustaka ini mencakup **Pandas** untuk mengelola data tabel/CSV, **NLTK** untuk pemrosesan teks (seperti memecah kata dan mencari kata dasar), **Scikit-Learn** untuk algoritma *machine learning* (TF-IDF, K-Means, dan PCA), serta **Matplotlib** untuk membuat grafik visualisasi.

2.

```
# Load dataset
file_path = "tmdb_5000_movies.csv"
df = pd.read_csv(file_path)

# Mengubah kolom 'overview' menjadi 'text' untuk klasterisasi
df = df.rename(columns={'overview': 'text'})

# Membersihkan baris yang nilai 'text'-nya kosong (NaN)
df = df.dropna(subset=['text'])
```

✓ 0.3s

Bertugas untuk membaca file dataset film (tmdb_5000_movies.csv) menggunakan Pandas. Karena algoritma selanjutnya memerlukan kolom bernama 'text', kita mengubah nama kolom sinopsis asli di dataset TMDB (yaitu **overview**) menjadi **text**. Selain itu, baris yang sinopsisnya kosong (NaN) dibersihkan menggunakan dropna agar tidak menyebabkan *error* pada tahap berikutnya.

```python
# Inisialisasi Lemmatizer
lemmatizer = WordNetLemmatizer()

# Fungsi preprocessing teks
def clean_text(text):
    text = text.lower() # Lowercasing
    text = re.sub(r'\d+', '', text) # Hapus angka
    text = text.translate(str.maketrans('', '', string.punctuation)) # Hapus tanda baca
    words = word_tokenize(text) # Tokenisasi
    words = [lemmatizer.lemmatize(word) for word in words] # Lemmatization
    return ' '.join(words)

# Terapkan preprocessing ke teks
df['clean_text'] = df['text'].apply(clean_text)

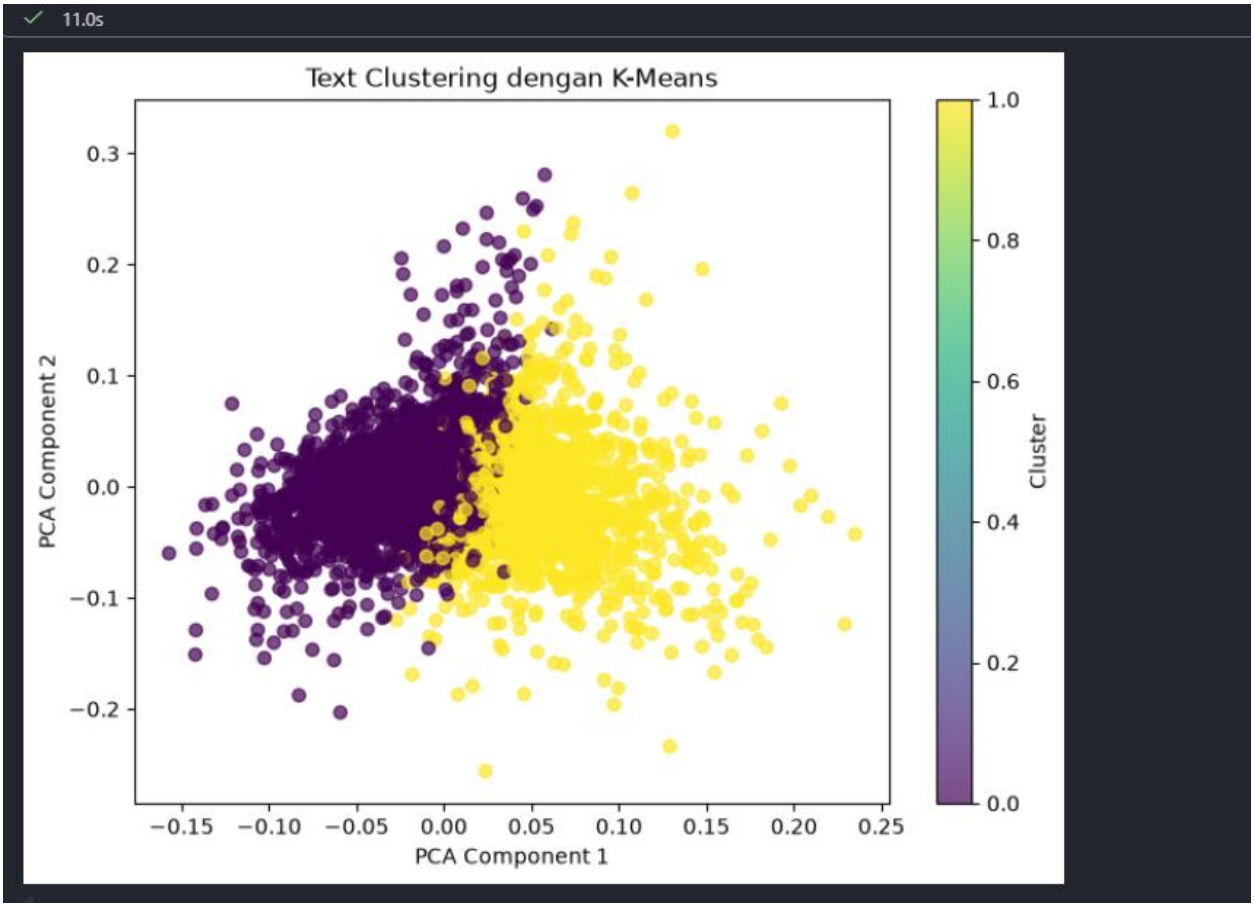
# Konversi teks ke vektor TF-IDF
vectorizer = TfidfVectorizer(stop_words='english') # Menggunakan stopwords dari sklearn
X = vectorizer.fit_transform(df['clean_text'])

# Tentukan jumlah klaster
num_clusters = 2
kmeans = KMeans(n_clusters=num_clusters, random_state=42, n_init=10)
df['cluster'] = kmeans.fit_predict(X)

# Visualisasi dengan PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X.toarray())

plt.figure(figsize=(8, 6))
plt.scatter(X_pca[:, 0], X_pca[:, 1], c=df['cluster'], cmap='viridis', alpha=0.7)
plt.xlabel("PCA Component 1")
plt.ylabel("PCA Component 2")
plt.title("Text Clustering dengan K-Means")
plt.colorbar(label='Cluster')
plt.show()
```

✓ 11.0s



Cell ini merupakan inti dari program yang menjalankan beberapa tahapan penting secara berurutan:

1. **Text Preprocessing (clean_text):** Membersihkan teks sinopsis film dengan mengubah semua huruf menjadi huruf kecil (*lowercasing*), menghapus angka, menghilangkan tanda baca, memecah kalimat menjadi kata-kata (*tokenization*), dan mengubah kata ke bentuk dasarnya (*lemmatization*).
2. **TF-IDF Vectorizer:** Mengubah teks yang sudah bersih menjadi representasi angka (vektor) berdasarkan tingkat pentingnya sebuah kata dalam dokumen, sekaligus membuang kata-kata umum yang kurang bermakna (*stopwords*) seperti *the, is, at*, dsb.
3. **K-Means Clustering:** Mengelompokkan data sinopsis film menjadi 2 klaster (num_clusters = 2) berdasarkan kemiripan pola kata di dalamnya menggunakan algoritma K-Means.
4. **PCA & Visualisasi (Scatter Plot):** Mereduksi ribuan dimensi fitur kata menjadi 2 dimensi (PCA(n_components=2)) agar dapat digambarkan ke dalam grafik 2D. Hasilnya ditampilkan menggunakan *scatter plot* dari Matplotlib dengan warna titik yang menunjukkan kelompok clusternya masing-masing.